SEMANA 1 · AULA 1 · 19/10

ENSINANDO MÁQUINAS

O que acontece entre o Enter e a resposta?

Felipe Oliveira · Soluções Digitais

<LAB365> SENAI

A SEMANA EM UM SLIDE

A PERGUNTA

O que acontece entre o Enter e a resposta do modelo?

TRÊS AULAS

Panorama, mecanismo e limites

PRÁTICAS

Nove dinâmicas em grupo, pontuação em todas

ENTREGÁVEL

Lista da semana até 26/10

3
aulas de 2h30

9
dinâmicas

9
papers originais

27
encontros no curso

AGENDA DE HOJE

19h00	O curso e a avaliação	EXPOSITIVO
19h15	D&D: criação de personagens	PRÁTICA
19h35	Bloco 1: como chegamos aqui	EXPOSITIVO
20h05	Intervalo	PAUSA
20h15	Classificador humano	PRÁTICA
20h40	Bloco 2: como usamos IA	EXPOSITIVO
21h05	Duelo humano x humano + IA e fechamento	PRÁTICA

AO FIM DA AULA

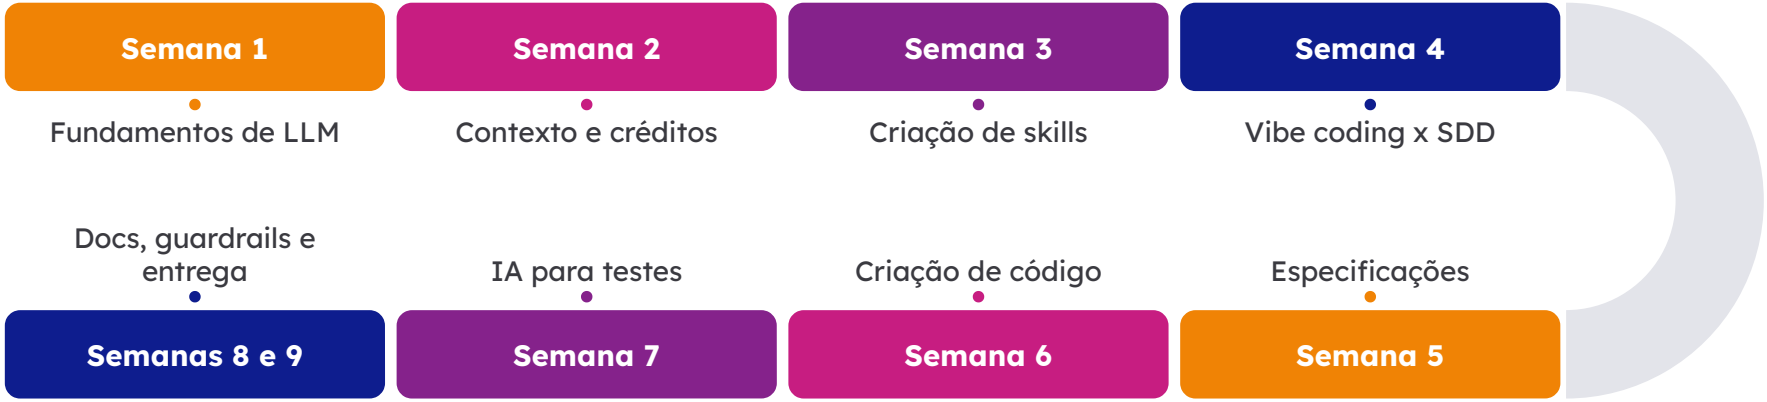
Você sai sabendo

- Situar LLM dentro da IA e explicar o que ele faz
- Distinguir assistente de agente de código
- Dizer o que a pesquisa mede sobre produtividade
- Seu grupo formado até o fim do curso

O CURSO E A AVALIAÇÃO

Como as 9 semanas funcionam e como você é avaliado

O CURSO EM 9 SEMANAS



COMO VOCÊ É AVALIADO

75%

de presença para certificar

7,0

de média mínima

2

avaliações com nota

> **Mini-projeto na semana 4 (Vibe x Spec) e projeto individual na semana 9: um software do seu trabalho, construído com spec, skills e guardrails.**
>
> Fio condutor do curso

D&D: CRIE SEU PERSONAGEM



CLASSE
O que você faz
Backend, frontend, dados, mobile, fullstack, infra

NÍVEL
Anos de estrada
Nível 1 a 20: um ponto por ano de experiência

ARMA FAVORITA
Sua linguagem
Python, Java, C#, JavaScript, Go, SQL

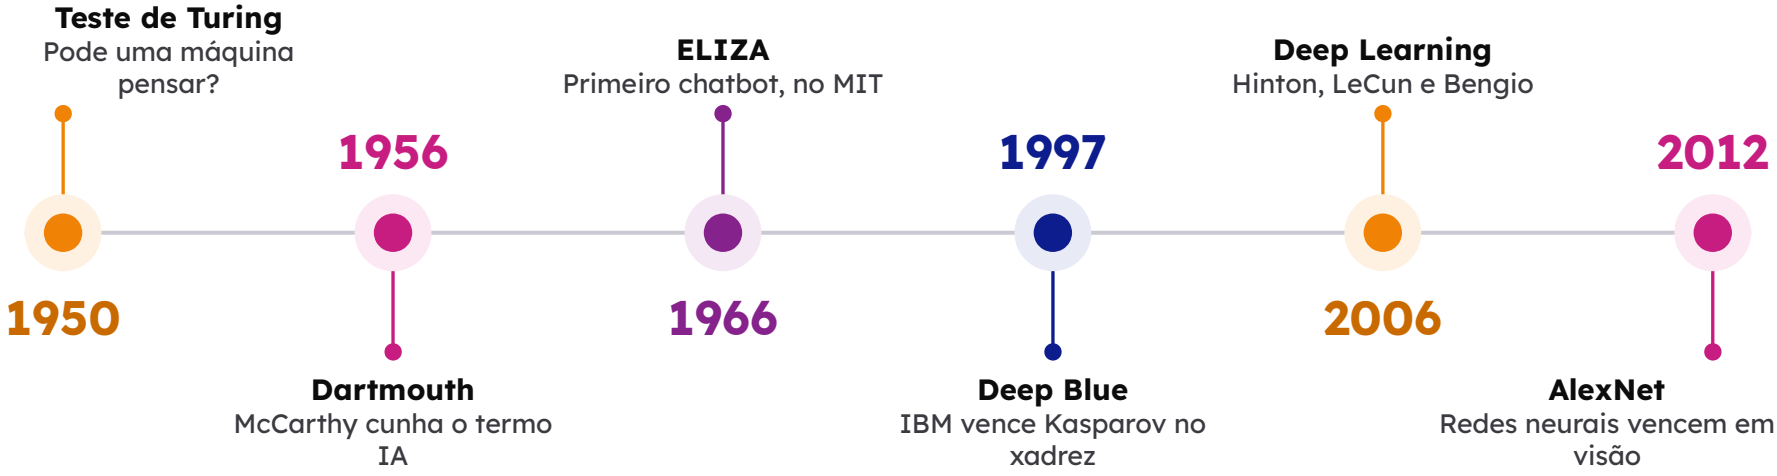
MAGIA DESEJADA
O que quer automatizar
A tarefa chata que você faria a IA fazer no trabalho

Grupos de 3 ou 4, classes misturadas: o grupo fica até o fim do curso e disputa todas as dinâmicas.

BLOCO 1: COMO CHEGAMOS AQUI

Onde o LLM se encaixa e o que ele faz

LINHA DO TEMPO: 1950 A 2012



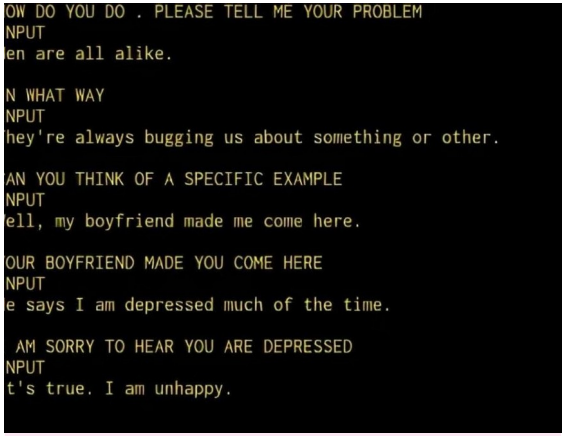
TRÊS MARCOS EM IMAGENS



1950

Alan Turing

Propôs o jogo da imitação: pode uma máquina se passar por humana numa conversa?



1966

ELIZA

Um roteiro de regras que reflete o que o usuário diz. Muita gente achou que ela entendia.

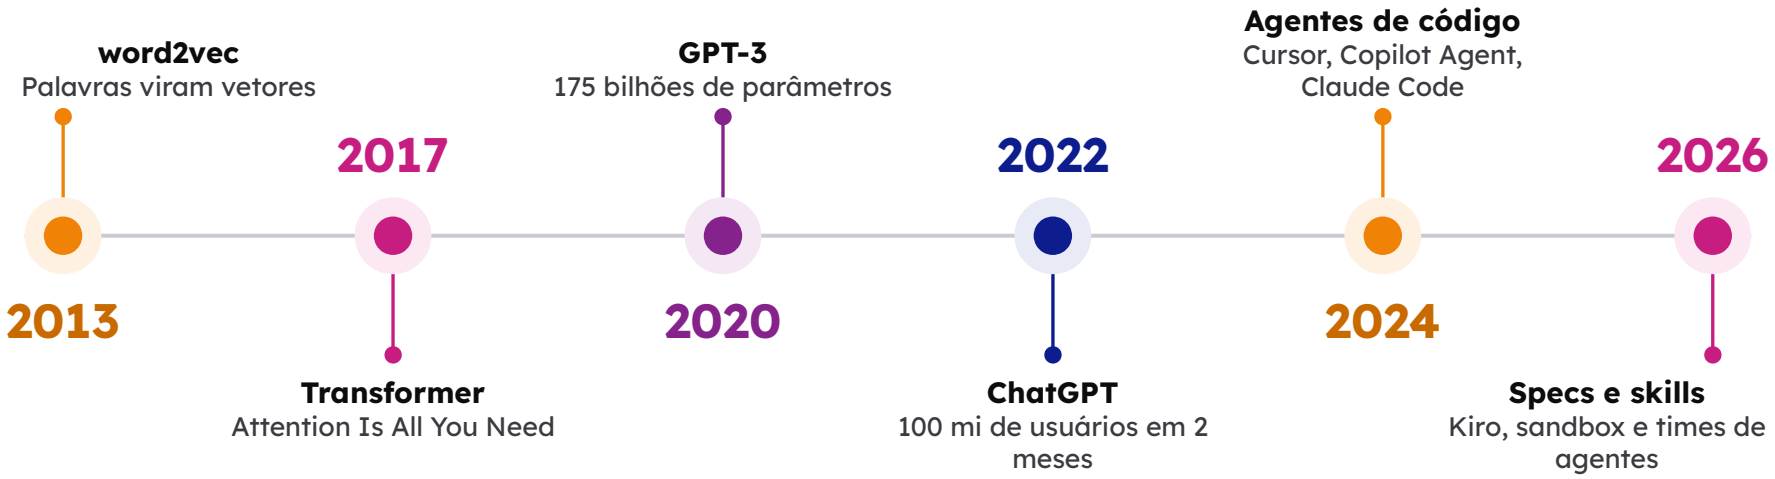


1997

Deep Blue

Venceu Kasparov avaliando 200 milhões de posições por segundo. Regras e força bruta, zero aprendizado.

LINHA DO TEMPO: 2013 A 2026



ONDE O LLM SE ENCAIXA



DISCRIMINATIVA X GENERATIVA

DISCRIMINATIVA

Responde: qual classe?

Pergunta	Isso é spam? É fraude? É gato ou cachorro?
Saída	Um rótulo ou um número
Exemplos	Filtro de spam, detecção de fraude, YOLO
Erro típico	Classificar errado

x

GENERATIVA

Responde: qual o próximo pedaço?

Pergunta	Como continua este texto ou código?
Saída	Conteúdo novo, token a token
Exemplos	ChatGPT, Copilot, Kiro, geradores de imagem
Erro típico	Inventar com confiança

Regra prática: se a saída é um rótulo, é discriminativa; se é conteúdo, é generativa.

O QUE É UM LLM EM UMA FRASE

> **Uma rede neural treinada para estimar a probabilidade do próximo token, dado tudo o que veio antes.**
>
> Definição que vale para GPT, Claude, Gemini e Llama

ENTRADA (O QUE VEIO ANTES)

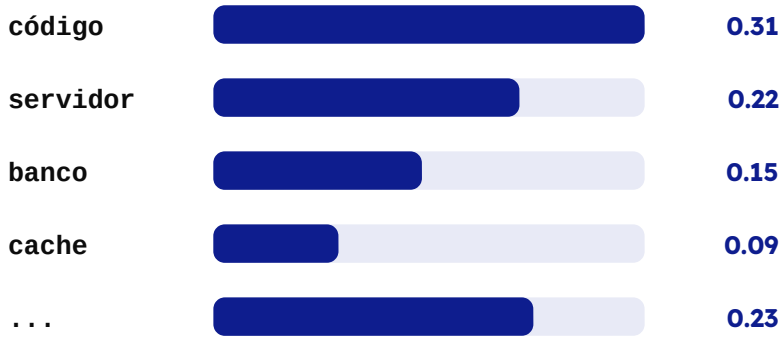
O bug está no → modelo

Não existe "a resposta certa" dentro do modelo.

Existe uma distribuição, e um sorteio a cada token.

É por isso que a mesma pergunta rende respostas diferentes (aula 2).

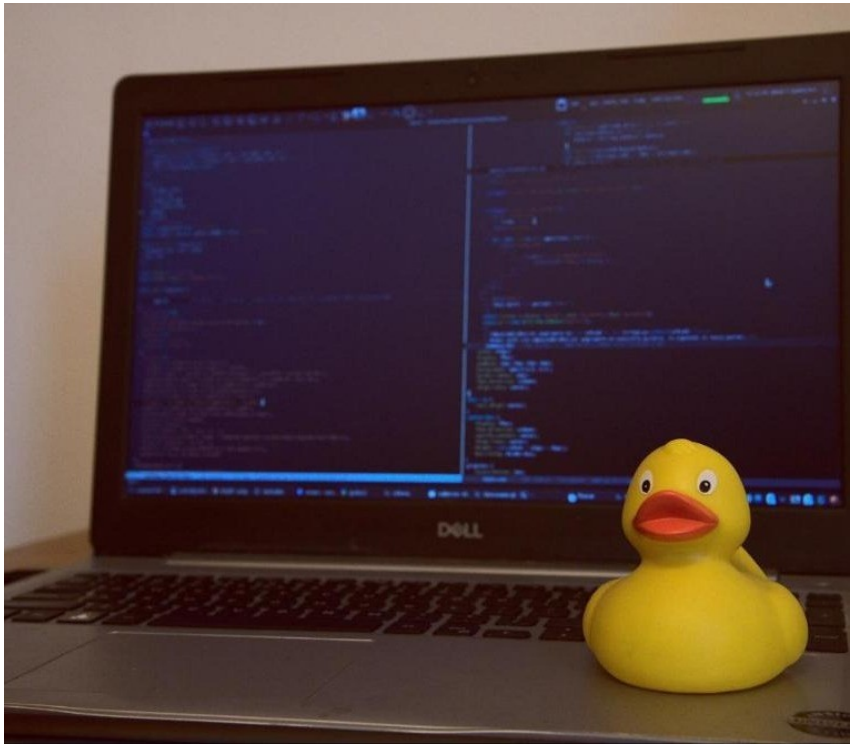
SAÍDA: P(PRÓXIMO TOKEN)



BLOCO 2: COMO USAMOS IA

Assistente, agente e o que a pesquisa mede

DO PATO DE BORRACHA AO AGENTE



PASSO 1

Pato

Você explica o código em voz alta. Ele não responde, mas você acha o bug.

PASSO 2

Assistente

Você explica. Ele responde, pergunta de volta, sugere a causa.

PASSO 3

Agente

Você dá o objetivo. Ele lê o código, testa a hipótese e volta com o resultado.

ASSISTENTE X AGENTE DE CÓDIGO

ASSISTENTE

Sugere e completa

Você	Pede, lê, cola, testa, volta a pedir
Ele	Autocomplete, chat, explicação
Alcance	Um arquivo, um trecho por vez
Exemplos	Copilot clássico, chat do ChatGPT

x

AGENTE

Executa e observa

Você	Dá o objetivo e revisa o resultado
Ele	Lê e edita arquivos, roda comandos, testa
Alcance	O repositório inteiro, vários passos
Exemplos	Kiro, Claude Code, Cursor Agent

O que muda é o laço: o agente age, observa o resultado e decide o próximo passo sozinho.

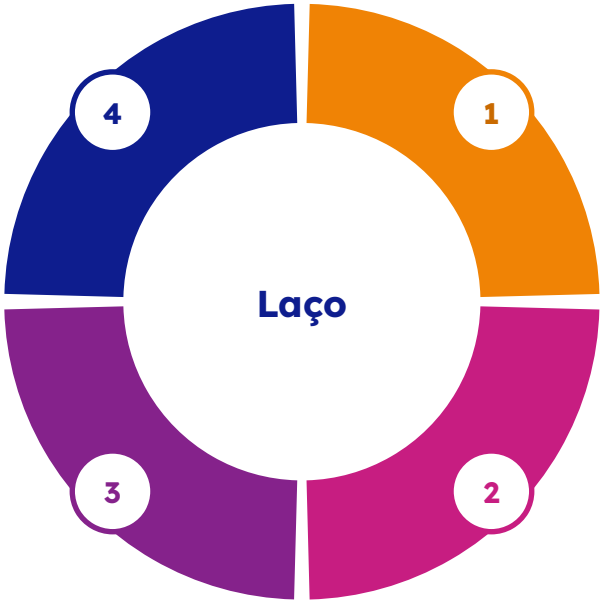
O LAÇO DO AGENTE

1. Ler
Objetivo, arquivos e regras do projeto

2. Agir
Edita código ou roda um comando

3. Observar
Lê o resultado: teste, erro, saída

4. Decidir
Continua, corrige ou encerra



FERRAMENTAS EM 2026

NA IDE

Copilot e Cursor

O QUE FAZ

Autocomplete, chat e modo agente dentro do editor

SPEC-DRIVEN

Kiro

O QUE FAZ

Agente com specs, steering, hooks e skills; IDE e CLI

NO TERMINAL

Claude Code e Gemini CLI

O QUE FAZ

Agente que opera o repositório pela linha de comando

CHAT GERAL

ChatGPT, Claude, Gemini

O QUE FAZ

Explicar, revisar, rascunhar; sem acesso ao seu código

NA NUVEM

Kiro Web, Codex, Jules

O QUE FAZ

Agentes que trabalham em tarefas longas fora da sua máquina

NA EMPRESA

Gateway de LLM

O QUE FAZ

Modelos via API corporativa, com cota, log e guardrails

HANDS-ON: CLASSIFICADOR HUMANO

1 Recebam os 12 cartões

5 MIN

Cada grupo recebe a mesma lista de produtos e ferramentas do slide seguinte.

2 Classifiquem em dois eixos

12 MIN

Eixo 1: discriminativa, generativa ou nenhuma. Eixo 2: assistente, agente ou não é IA. Escrevam o critério usado.

3 Revelação e debate

8 MIN

Comparem com o gabarito. Defendam os cartões polêmicos: quem convence o júri ganha o ponto.

COMO PONTUAR

+1	cartão na classe certa
+2	justificativa que cita o critério
+1	convencer a turma num cartão polêmico

PARA DISCUTIR

- Qual cartão dividiu o grupo?
- O que define agente: a ferramenta ou o laço?

OS 12 CARTÕES

01 Filtro de spam do Gmail

02 Recomendação da Netflix

03 Autocomplete do Copilot

04 Chat do ChatGPT

05 Kiro executando uma spec

06 Detector de placas no estacionamento

07 Corretor ortográfico

08 Gerador de imagens

09 GitHub Actions rodando testes

10 Tradutor automático

11 Classificador de sentimento de reviews

12 Agente que abre PR sozinho

GABARITO DOS 12 CARTÕES

1	Filtro de spam do Gmail	DISCRIM.	NENHUM
2	Recomendação da Netflix	DISCRIM.	NENHUM
3	Autocomplete do Copilot	GENERATIVA	ASSISTENTE
4	Chat do ChatGPT	GENERATIVA	ASSISTENTE
5	Kiro executando uma spec	GENERATIVA	AGENTE
6	Detector de placas	DISCRIM.	NENHUM
7	Corretor ortográfico	D + G	ASSISTENTE
8	Gerador de imagens	GENERATIVA	ASSISTENTE
9	GitHub Actions rodando testes	NÃO É IA	NENHUM
10	Tradutor automático	GENERATIVA	ASSISTENTE
11	Classificador de sentimento	DISCRIM.	NENHUM
12	Agente que abre PR sozinho	GENERATIVA	AGENTE

LARANJA = CARTÃO POLÊMICO, VALE DEBATE. EIXO 1: DISCRIMINATIVA OU GENERATIVA. EIXO 2: ASSISTENTE, AGENTE OU NENHUM.

DUELO: HUMANO X HUMANO + IA

1 Dois voluntários, uma tarefa

2 MIN

Um resolve sem IA. O outro com o chat de IA que quiser. Os dois projetam a tela. Tarefa e testes no próximo slide.

2 Corrida com apostas

6 MIN

Enquanto eles codam, cada grupo anota: quem termina primeiro e com quantos minutos de vantagem. Terminou = passou nos 3 testes.

3 Revelação

7 MIN

Conferir os testes. Pagar as apostas. Depois, o que a pesquisa mediu: o próximo slide tem um número que vai surpreender.

COMO PONTUAR

+2	acertou quem venceu
+2	acertou a diferença (margem de 1 min)
+1	apontar um erro no código do vencedor

REGRA DE OURO

- Rodou não é terminou: terminou é passar nos testes
- Vale para o resto do curso

A TAREFA DO DUELO

tarefa.py

```
# Escreva valida_cpf(cpf: str) -> bool
# Aceita "123.456.789-09" e "12345678909"
# Rejeita dígitos repetidos ("111.111.111-11")
# Rejeita dígito verificador errado

def valida_cpf(cpf: str) -> bool:
    ...

# Testes (precisam passar os 3):
assert valida_cpf("529.982.247-25") is True
assert valida_cpf("111.111.111-11") is False
assert valida_cpf("529.982.247-26") is False
```

REGRAS

Condições iguais

- Mesma linguagem para os dois (Python ou JS)
- Sem IA: só editor e documentação oficial
- Com IA: qualquer chat gratuito, copiar e colar liberado
- Cronômetro no telão; para no 1º que passar nos 3 testes

O QUE A PESQUISA MEDIU



mais lentos com IA (METR, 2025)



mais rápidos, na opinião deles



dos devs confiam na resposta da IA

> **Percepção não é medição. A ferramenta não traz produtividade embutida: o método vem antes. Por isso o curso mede, não opina.**
>
> Becker et al. 2025 (arXiv:2507.09089) e Stack Overflow Developer Survey 2025

O PAPEL DO DEV ESTÁ MUDANDO

ANTES

Escrever era o trabalho

Código	Linha por linha, de cabeça
Dúvida	Google e Stack Overflow
Depuração	Horas de print e breakpoint
Docs e testes	No fim, se sobrar tempo

COM AGENTES

Especificar e revisar é o trabalho

Código	Gerado; você revisa e decide
Dúvida	Contexto certo para o agente
Depuração	Agente diagnostica; você valida
Docs e testes	Junto com o código, sempre

A habilidade que sobe de valor: fazer a pergunta certa e validar criticamente o que volta.

TAREFA PARA A AULA 2

PASSO 1

Python e tiktoken

Python 3.10+ e pip install tiktoken.
Teste: import tiktoken

PASSO 2

Conta Google

Para o Google AI Studio na aula 2
(gratuito, sem cartão)

PASSO 3

Git e GitHub

Git instalado e conta no GitHub para a lista da semana

A partir da semana 3: Kiro IDE e Kiro CLI serão a ferramenta das práticas. O guia de instalação chega na sexta, 23/10. Não precisa instalar antes.

LISTA DA SEMANA 1

1

tokens.py

Script que recebe um arquivo e imprime caracteres, tokens e a razão. Rodar num código seu e num README em português.

2

Três temperaturas

O mesmo prompt 3 vezes em 3 temperaturas no AI Studio. Tabela das respostas e um parágrafo sobre o que mudou.

3

Pacote verificado

Uma dependência sugerida pela IA para um problema real do seu trabalho, conferida no PyPI ou npm, com print.

4

Preparação

Instalar Kiro IDE e Kiro CLI com o guia de sexta. Só precisa estar pronto na semana 3.

SEMANA 1 · AULA 2 · 21/10

FALANDO COM MÁQUINAS

Tokens, vetores, atenção e o sorteio do próximo token

Felipe Oliveira · Soluções Digitais

<LAB365> SENAI

AGENDA DE HOJE

19h00	Retomada: a pergunta da semana	EXPOSITIVO
19h10	Bloco 3: tokens	EXPOSITIVO
19h35	Tokens na balança	PRÁTICA
20h05	Intervalo	PAUSA
20h15	Bloco 4: embeddings e atenção	EXPOSITIVO
20h35	Batalha de vetores	PRÁTICA
21h05	Bloco 5 + Cassino do próximo token	MISTO

AO FIM DA AULA

Você sai sabendo

- Contar tokens e prever o custo de um prompt
- Explicar por que português custa mais que inglês
- Ler um embedding como posição num espaço
- Dizer o que temperatura muda e o que não muda

BLOCO 3: TOKENS

O modelo não lê letras nem palavras

O MODELO NÃO LÊ LETRAS

tokenização	`token` `ização`	2 TOKENS
tokenization	`token` `ization`	2 TOKENS
desenvolvedor	`des` `envol` `vedor`	3 TOKENS
developer	`developer`	1 TOKEN
autenticação	`aut` `ent` `icação`	3 TOKENS
authentication	`authentication`	1 TOKEN



TOKEN

Pedaço de texto

Pode ser uma palavra inteira, uma sílaba, um prefixo, um espaço ou pontuação.

O modelo só vê números: o id de cada token no vocabulário.

Vocabulários atuais: 100 mil a 200 mil tokens.

COMO O BPE APRENDE OS PEDAÇOS

01

Bytes

Vocabulário inicial: os 256 bytes

02

Contar pares

O par adjacente mais frequente no corpus

03

Fundir

O par vira um token novo do vocabulário

04

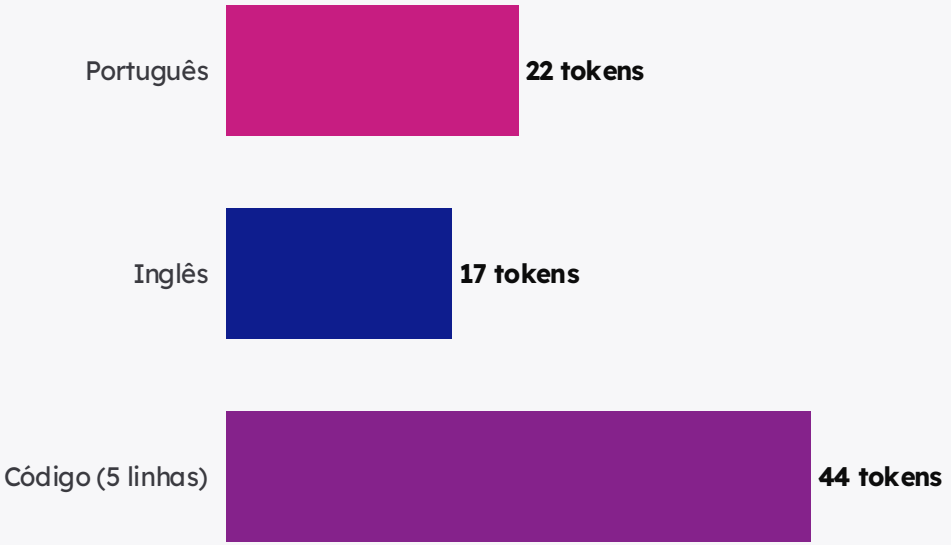
Repetir

Até o tamanho escolhido: 100k, 200k

Só frequência, nada de gramática: o que aparece muito no treino vira um token só. O inglês aparece muito mais.

PORTUGUÊS CUSTA MAIS

TOKENS PARA DIZER A MESMA COISA (o200k_base)



4,1 caracteres por token em português

5,6 caracteres por token em inglês

4,4 caracteres por token em código

CÓDIGO MÍNIMO: CONTAR TOKENS

tokens.py

```
import tiktoken

enc = tiktoken.get_encoding("o200k_base")

texto = "O desenvolvedor refatorou a função"
ids = enc.encode(texto)

print(len(texto), "caracteres")
print(len(ids), "tokens")
print([enc.decode([t]) for t in ids])

# 34 caracteres
# 8 tokens
# ['O', ' desenvolved', 'or', ' refator', 'ou', ' a', ' fun',
'ção']
```

O QUE OBSERVAR

Três detalhes

- O espaço faz parte do token: ' refator' e não 'refator'
- A mesma palavra pode quebrar diferente conforme a vizinhança
- O vocabulário baixa uma vez e fica em cache
- o200k_base é o do GPT-4o em diante; cl100k_base, dos anteriores

HANDS-ON: TOKENS NA BALANÇA

1 Meçam três textos

10 MIN

Uma frase em português, a mesma em inglês e 10 linhas de código do seu trabalho. Anotem caracteres, tokens e a razão.

2 Caçada por grupo

12 MIN

Encontrem a palavra em português que gasta MAIS tokens e a que gasta MENOS (mínimo 8 letras cada).

3 Expliquem o resultado

8 MIN

Por que acentos e palavras raras custam mais? O que isso muda num prompt longo ou num arquivo colado no contexto?

COMO PONTUAR

+1	por token de diferença entre a maior e a menor
+2	tabela completa dos três textos
+2	explicação que cite o BPE

DICA

- Tente palavras com ç, ã e õ
- Tente nomes de variáveis em camelCase

BLOCO 4: EMBEDDINGS E ATENÇÃO

De token a vetor, de vetor a significado

DE TOKEN A VETOR

01

Token

" gato" é o id 9304 do vocabulário

02

Vetor

O id vira 1.536 números aprendidos

03

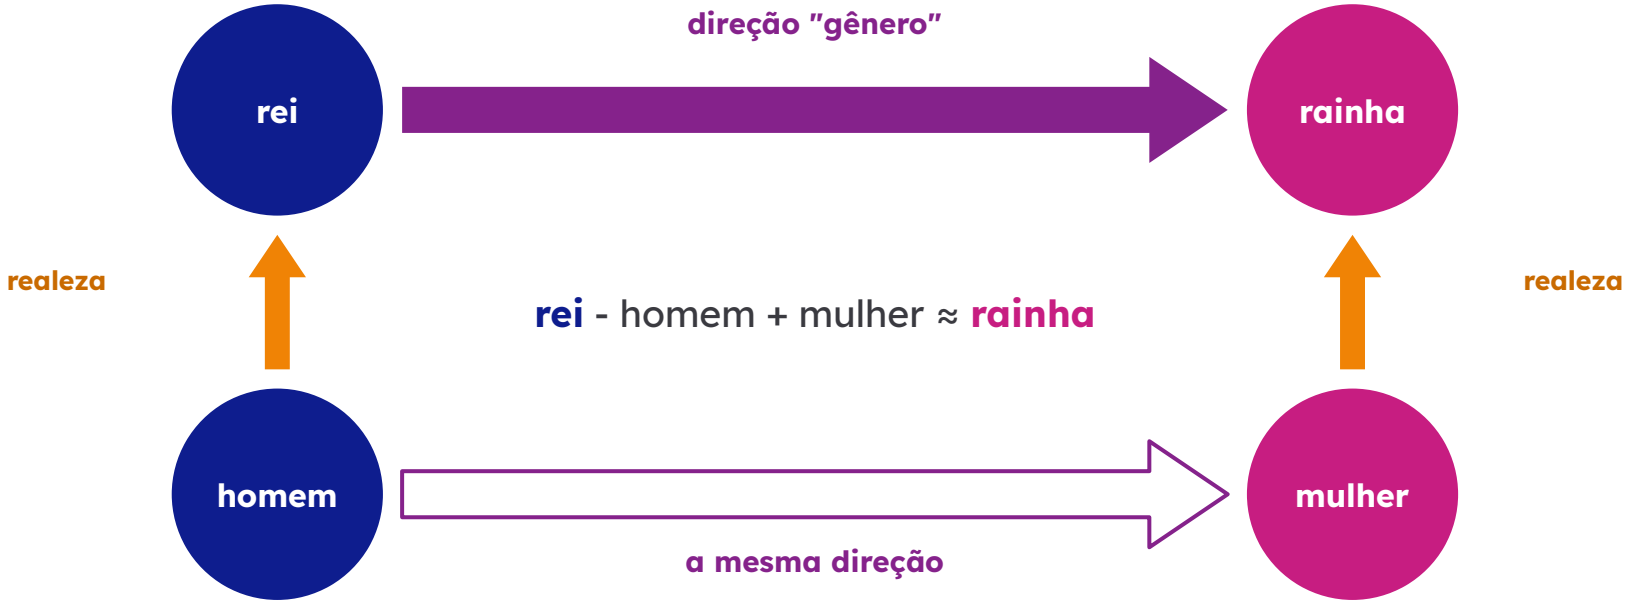
Posição

Perto: cachorro, felino. Longe: compilador

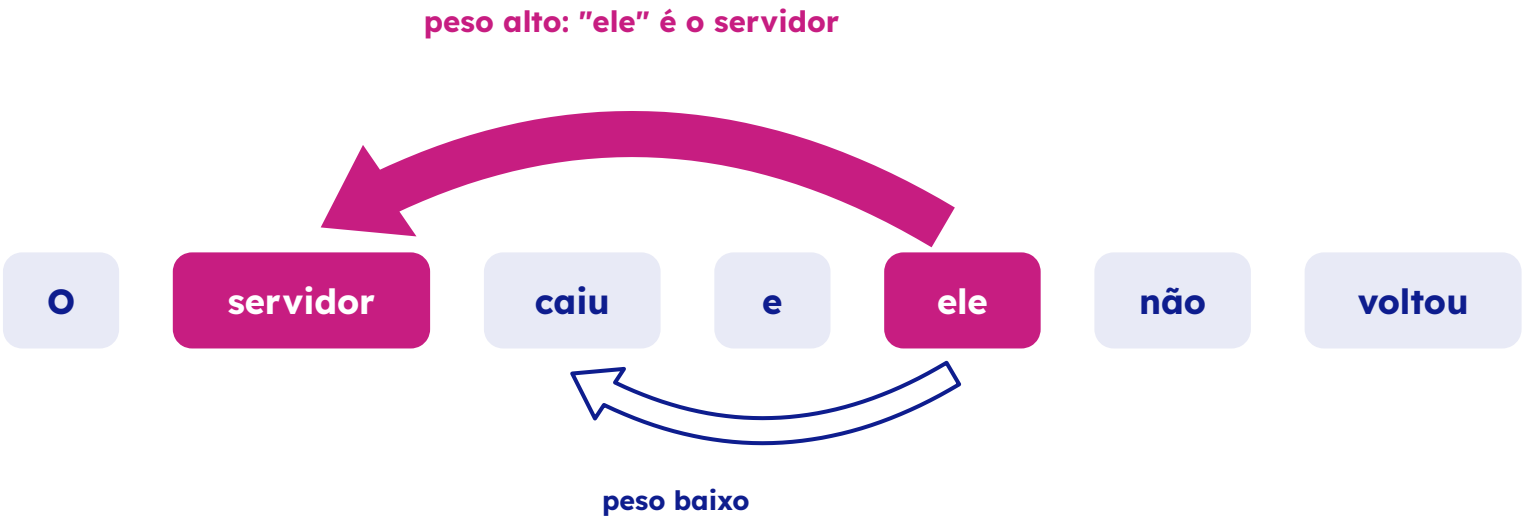
```
" gato"
[ 0.021, -0.173,  0.448,  0.009, -0.312,  0.127, ... 1.530 números a mais ...,  0.084 ]
```

A posição nesse espaço é o "significado" que o modelo conhece. Distância pequena = uso parecido.

ARITMÉTICA COM SIGNIFICADO



ATENÇÃO: QUEM OLHA PARA QUEM

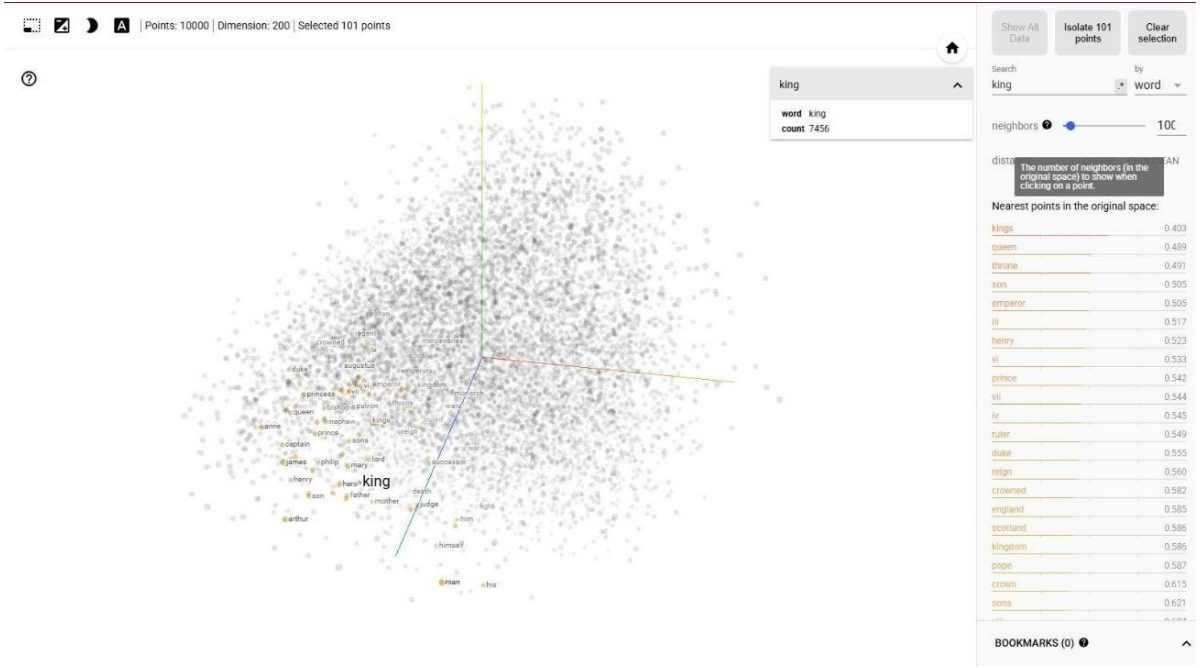


Custo: cada token se compara com todos os anteriores. Dobrar o contexto mais que dobra o trabalho. Guarde isso para a aula 3.

O TRANSFORMER EM UM SLIDE



O EMBEDDING PROJECTOR



WORD2VEC 10K

Vizinhos de "king"

- kings 0,40 e queen 0,49: os mais próximos
- throne, emperor, prince, ruler, crown
- Nenhuma definição foi ensinada: só contexto de uso
- É aqui que a Batalha de vetores acontece

HANDS-ON: BATALHA DE VETORES

1 Escolham a palavra secreta

12 MIN

No Embedding Projector (Word2Vec 10K), busquem a palavra e copiem as 10 vizinhas mais próximas. Enviem só a lista ao grupo adversário.

2 Descubram a do adversário

12 MIN

Explorem cada vizinha no Projector. Três tentativas para nomear a palavra secreta.

3 Revelação

6 MIN

Revelem as palavras. Por que essas vizinhas? O que o modelo aprendeu sobre a palavra?

COMO PONTUAR

+3	acertou na 1ª tentativa
+2	acertou na 2ª
+1	acertou na 3ª
0	não acertou

DICA DE ATAQUE

- Palavras ambíguas confundem: bank, apple, java
- Campo semântico denso ajuda a esconder

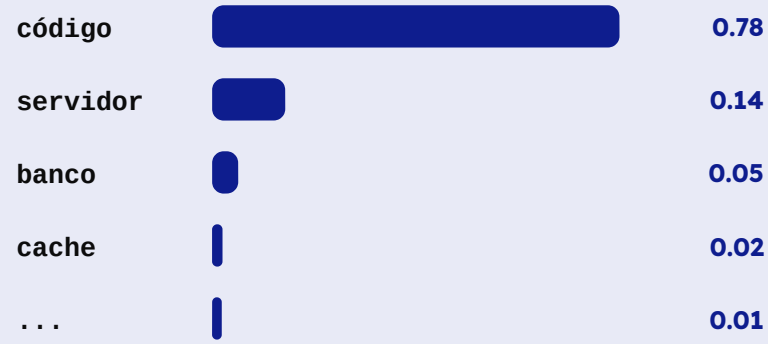
BLOCO 5: GERAR É SORTEAR

Temperatura e por que a resposta muda

O QUE A TEMPERATURA MUDA

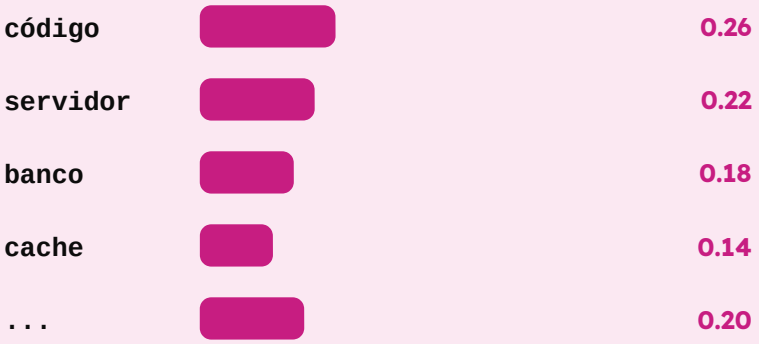
TEMPERATURA 0,2

afia a distribuição



TEMPERATURA 1,5

achata a distribuição



O que não muda: a temperatura não deixa o modelo mais inteligente nem mais certo. Ela só muda quanto do acaso entra no sorteio.

"RODOU UMA VEZ" NÃO É TESTE

1

Mesma pergunta, outra resposta

Dois colegas com o mesmo prompt recebem códigos diferentes. Nenhum dos dois é 'o certo'.

2

Bug que não volta

Para reproduzir um erro gerado por IA, guarde o prompt, o modelo e o contexto inteiro.

3

Uma execução não prova

Avaliar uma saída de LLM exige amostra: rode várias vezes e conte.

4

Determinismo é falso conforto

Temperatura 0 reduz a variação, mas não a elimina. Teste é o que garante.

HANDS-ON: CASSINO DO PRÓXIMO TOKEN

1 Façam as apostas

4 MIN

Prompt fixo: "Complete em uma frase: o maior risco de usar IA para gerar código é". Quantas das 3 respostas serão idênticas em cada temperatura (0, 1 e 2)?

2 Rodem 9 vezes

10 MIN

No AI Studio: 3 vezes com temperatura 0, 3 com 1, 3 com 2. Colem as 9 respostas numa tabela.

3 Comparem com a aposta

6 MIN

Temperatura 0 garantiu 3 iguais? O que isso significa para reproduzir um bug que a IA causou?

COMO PONTUAR

+1	por aposta certa (3 possíveis)
+1	tabela com as 9 respostas
+2	explicação usando a distribuição

PLANO B

- Sem acesso: professor roda no projetor
- Grupos apostam e discutem

O QUE VIMOS E O QUE VEM

TOKENS

O modelo lê pedaços; português custa mais

VETORES

Significado é posição num espaço

ATENÇÃO

Cada token pesa os outros; custo cresce com o contexto

SORTEIO

Temperatura regula o acaso; rodar uma vez não é teste

AULA 3 · QUI 22/10

Os limites da máquina

- Janela de contexto: até onde o modelo vê
- Data de corte: o que ele não sabe
- Alucinação e pacotes que não existem
- Mais contexto não é melhor

SEMANA 1 · AULA 3 · 22/10

OS LIMITES DA MÁQUINA

Janela de contexto, data de corte e alucinação

Felipe Oliveira · Soluções Digitais

<LAB365> SENAI

AGENDA DE HOJE

19h00	Retomada	EXPOSITIVO
19h10	Bloco 6: janela de contexto e treino	EXPOSITIVO
19h35	História de pescador	PRÁTICA
20h10	Intervalo	PAUSA
20h20	Bloco 7: alucinação e pacotes fantasma	EXPOSITIVO
20h35	Pacote fantasma	PRÁTICA
20h55	Bloco 8 + Agulha no palheiro + fechamento	MISTO

AO FIM DA AULA

Você sai sabendo

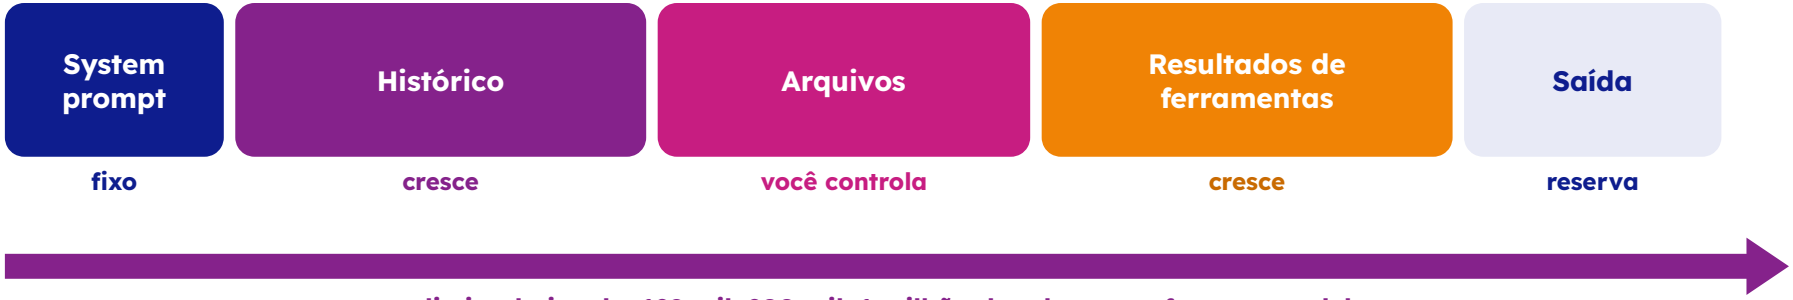
- Desenhar o que entra na janela de contexto
- Explicar por que o modelo chuta em vez de dizer 'não sei'
- Verificar uma dependência antes do install
- Posicionar a instrução importante num prompt longo

BLOCO 6: JANELA DE CONTEXTO

Até onde o modelo vê e desde quando ele sabe

A JANELA DE CONTEXTO

UMA JANELA, TUDO SOMADO (ENTRADA + SAÍDA)



FORA DA JANELA

O modelo não vê

O que saiu da janela não existe para ele. Não há memória entre sessões por padrão.

O QUE PARECE MEMÓRIA

É texto reinjetado

Resumo do histórico, arquivo de regras, notas: alguém põe de volta no contexto.

COMO O MODELO É TREINADO

01

Pré-treino

Prever o próximo token em trilhões de tokens da internet e de código. Resultado: completa texto, não conversa.

02

Instrução

Exemplos de pergunta e resposta escritos por pessoas. Aprende o formato de assistente.

03

RLHF

Pessoas comparam respostas; um modelo de recompensa ensina o que é 'boa resposta'.

Data de corte: é o fim do pré-treino. O que aconteceu depois, o modelo só sabe se alguém puser no contexto: busca, documento, ferramenta.

O MODELO E O CALENDÁRIO



Como corrigir: busca, documentação colada no contexto ou ferramenta que consulta a fonte. Nunca a memória do modelo.

HANDS-ON: HISTÓRIA DE PESCADOR

1 Construam a armadilha

12 MIN

Peçam à IA 5 afirmações sobre uma tecnologia (biblioteca, linguagem, versão). Editem e escondam 2 mentiras plausíveis: mude uma data, um nome, um número.

2 Detectem a mentira

12 MIN

Recebam as 5 do adversário. Usem outra IA para checar cada uma. Apontem as 2 mentiras e justifiquem com fonte.

3 Revelação

8 MIN

Gabaritos abertos. Onde a IA confirmou mentira como verdade? Qual afirmação enganou mais e por quê?

COMO PONTUAR

+1	por mentira detectada
+1	por mentira que passou
+2	pegar a IA confirmando uma mentira

REGRA

- Mentira boa muda um detalhe só
- Fonte vale mais que a resposta da IA

BLOCO 7: ALUCINAÇÃO

Por que o modelo chuta e o que isso custa

POR QUE MODELOS ALUCINAM

> **Como estudantes diante de questões difíceis, os modelos chutam quando estão incertos. O treino e a avaliação recompensam o chute, não a admissão de incerteza.**
>
> Kalai, Nachum, Vempala e Zhang, 2025 (arXiv:2509.04664), tradução livre

NA PROVA
Chutar pontua

"Não sei"	0 pontos, sempre
Chute	Às vezes acerta: pontos
Resultado	Aprende a chutar com confiança

x

NO SEU CÓDIGO
Chutar custa

"Não sei"	Seria a resposta útil
Chute	Método inexistente, API inventada
Resultado	Você descobre em produção

PACOTES QUE NÃO EXISTEM

5,2%

de pacotes inexistentes em modelos comerciais

21,7%

em modelos open-source

205 mil

nomes de pacote inventados, únicos

> **576 mil amostras de código em Python e JavaScript, 16 modelos. O pip install que o modelo sugeriu pode não existir. Ou pior: pode existir.**
>
> Spracklen et al., USENIX Security 2025 (arXiv:2406.10279)

SLOPSQUATTING

01

Modelo inventa

Sugere 'fastjson-utils', que não existe. E repete o mesmo nome para outros devs.

02

Atacante registra

Publica um pacote com esse nome no PyPI ou npm, com código malicioso dentro.

03

Dev instala

Confia na sugestão, roda pip install, o pacote existe, tudo parece certo.

04

Código roda

Na sua máquina, no CI ou em produção. Com as suas credenciais.

Regra que fica para o curso: dependência sugerida por IA passa pelo registro antes do install: existe? é mantida? faz o que o modelo disse?

HANDS-ON: PACOTE FANTASMA

1 Peçam uma biblioteca

6 MIN

Para uma tarefa obscura: ler .dbf do Clipper em Python, converter PDF da Receita em JSON, parsear logs do Zabbix em Node. Peçam nome e exemplo de uso.

2 Verifiquem no registro

8 MIN

pypi.org ou npmjs.com: existe? último release? faz o que o modelo disse? O exemplo de uso bate com a documentação?

3 Contem os fantasmas

6 MIN

Comparem com os 5,2% e 21,7% do paper. Quantos fantasmas em 10 pedidos?

COMO PONTUAR

+2	pacote que não existe
+1	pacote real, mas abandonado
+1	exemplo de uso que não bate com a doc

REGRA

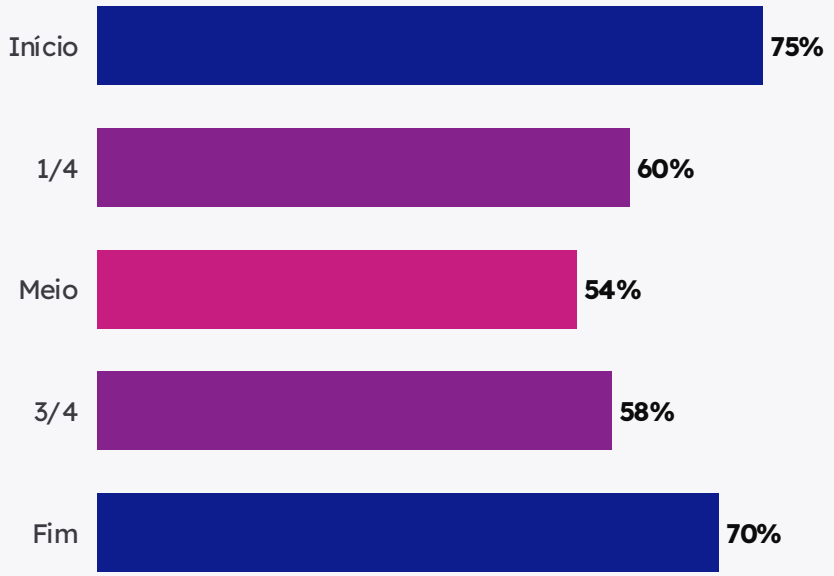
- Registro antes do install
- Sempre, mesmo quando o nome parece familiar

BLOCO 8: CONTEXTO DEMAIS

Posição e volume importam: mais não é melhor

LOST IN THE MIDDLE

ACURÁCIA POR POSIÇÃO DA INFORMAÇÃO (forma da curva, Liu et al. 2023)



O QUE FAZER

Posição importa

- Instrução importante no início ou no fim do prompt
- Arquivo mais relevante primeiro, não no meio de 20 arquivos
- Repita a restrição crítica no fim
- Contexto curto rende mais que contexto cheio

CONTEXT ROT

18

modelos testados, de 4 empresas

113k

tokens por prompt no teste de memória

↓

desempenho cai com o tamanho da entrada

> **O desempenho fica cada vez menos confiável conforme a entrada cresce, mesmo em tarefas simples. Janela grande não é licença para encher o contexto.**
>
> Hong, Troynikov e Huber, Chroma Technical Report, 2025

O CONTEXTO DE UM AGENTE DE CÓDIGO



HANDS-ON: AGULHA NO PALHEIRO

1 Montem o palheiro

8 MIN

Texto de 2 a 3 páginas (pode gerar com a IA). Escondam a frase-chave 'a senha do cofre é 4817' no início, no meio ou no fim.

2 Perguntem 9 vezes

10 MIN

Colem o texto e perguntem: qual é a senha do cofre? Três vezes por posição. Registrem acertos.

3 Comparem com a curva

7 MIN

Onde o modelo errou mais? Bate com Lost in the Middle? O que muda na forma de montar um prompt longo?

COMO PONTUAR

+1	por acerto registrado com evidência
+2	tabela com as 3 posições
+2	conclusão ligada à curva

VARIAÇÃO

- Troque a senha por uma instrução: 'responda em inglês'
- Ela é obedecida no meio?

REGRAS QUE FICAM PARA O CURSO

1

Rodar uma vez não é teste

A saída é um sorteio. Avalie com amostra, guarde prompt, modelo e contexto.

2

Registro antes do install

Dependência sugerida por IA: existe? é mantida? faz o que o modelo disse?

3

Instrução importante nas pontas

Início ou fim do prompt. Repita a restrição crítica. Nunca enterre no meio.

4

Contexto enxuto

Só os arquivos relevantes. Janela grande não é licença para colar tudo.

A PERGUNTA DA SEMANA, RESPONDIDA

O TEXTO VIRA TOKENS

Pedaços frequentes; português custa mais

A ATENÇÃO MISTURA O CONTEXTO

Cada token pesa os outros, dentro da janela

O PRÓXIMO TOKEN É SORTEADO

Temperatura regula o acaso

O MODELO CHUTA QUANDO NÃO SABE

Verifique fatos, pacotes e posições

SEMANA 2 · COM WANDERSON

Contexto e créditos

- Quanto cada pedaço da janela custa
- Como medir o consumo de créditos
- Como enxugar o contexto sem perder qualidade
- Entrega da lista 1 até segunda 26/10


<LAB365>
SENAI