SEMANA 1 · AULA 2 · 21/10

FALANDO COM MÁQUINAS

Bag of Words, tokens, vetores e atenção

Felipe Oliveira · Soluções Digitais

<LAB365> SENAI

AGENDA DE HOJE

19h00	Retomada: entre o Enter e a resposta	EXPOSITIVO
19h10	Parte 1: Bag of Words	EXPOSITIVO
19h30	Hands-on 1: recrie o Bag of Words	PRÁTICA
19h50	Parte 2: tokenização BPE	EXPOSITIVO
20h10	Intervalo	PAUSA
20h20	Hands-on 2: recrie o tokenizador	PRÁTICA
20h50	Parte 3 + Hands-on 3: espaço 3D	MISTO

AO FIM DA AULA

Você sai sabendo

- Explicar por que Bag of Words não captura sentido
- Descrever como o BPE aprende os tokens
- Ler um embedding como posição num espaço
- Especificar e verificar código gerado por IA

A PERGUNTA DA SEMANA

AULA 1	AULA 2 · HOJE	AULA 3
Panorama	**Mecanismo**	**Limites**
O LLM estima a probabilidade do próximo token	Como o seu texto vira números: contagem, tokens e vetores	Temperatura, janela de contexto, data de corte e alucinação

A PERGUNTA

O que acontece entre o Enter e a resposta do modelo?

Antes de prever qualquer token, o modelo precisa transformar texto em números. Hoje vemos três jeitos de fazer isso, do mais antigo ao atual.

PARTE 1: BAG OF WORDS

Antes dos embeddings, texto era contagem

TEXTO COMO CONTAGEM

01

Documentos

Frases, e-mails, arquivos inteiros: cada um vira uma linha

02

Vocabulário

Cada palavra única do conjunto vira uma coluna

03

Contagem

A célula guarda quantas vezes a palavra aparece no documento

"o gato dormiu no sofá"

```
[ o: 1, gato: 1, dormiu: 1, no: 1, sofá: 1, felino: 0, servidor: 0, cão: 0, ... mais 49.990 zeros ]
```

Uma coluna por palavra. Com 50 mil palavras no vocabulário, uma frase curta é quase só zero: a matriz é esparsa.

A MATRIZ ESPARSA

DOCUMENTO	o	gato	dormiu	no	sofá	da	sala	felino	servidor	cão	mordeu	homem	...
Doc 1 o gato dormiu no sofá da sala	1	1	1	1	1	1	1	0	0	0	0	0	...
Doc 2 o felino dormiu no sofá da sala	1	0	1	1	1	1	1	1	0	0	0	0	...
Doc 3 o servidor dormiu no sofá da sala	1	0	1	1	1	1	1	0	1	0	0	0	...
Doc 4 o cão mordeu o homem	2	0	0	0	0	0	0	0	0	1	1	1	...
Doc 5 o homem mordeu o cão	2	0	0	0	0	0	0	0	0	1	1	1	...

52% de zeros com 12 palavras. Num vocabulário real de 50 mil, as reticências escondem mais 49.988 colunas zeradas: cada linha passa de 99,98% de zeros.

ESPARSO E CEGO

1

Esparso

50 mil colunas para guardar 5 palavras. Mais de 99,9% da linha é zero.

2

Sem sentido

Gato e felino ficam tão longe quanto gato e servidor. Palavras diferentes são sempre perpendiculares.

3

Sem ordem

"O cão mordeu o homem" e "o homem mordeu o cão" viram exatamente o mesmo vetor.

4

TF-IDF ajuda, não cura

Pesar palavras raras melhora a busca, mas o vetor segue sem sentido e sem ordem.

REGRAS DOS TRÊS HANDS-ON

1

Qualquer IA vale

ChatGPT, Claude, Gemini, Copilot ou Kiro. A ferramenta é escolha do grupo.

2

Histórico é entrega

Cada grupo entrega o código e o histórico completo de prompts. Sem histórico, sem ponto.

3

Especifique antes

O primeiro prompt diz entrada, saída e regras. "Faz um bag of words" não é especificação.

4

Rodou não é terminou

Terminou é passar no teste do slide. Conferir faz parte do exercício.

HANDS-ON 1: RECRIE O BAG OF WORDS

1 Especifiquem

5 MIN

Frases entram; vocabulário, matriz documento-termo e similaridade de cosseno saem. Sem scikit-learn.

2 Construam com IA

10 MIN

Qualquer linguagem. Peçam que a IA explique o código antes de aceitar. Rodem com as 5 frases do artefato.

3 Testem

5 MIN

"Cão mordeu homem" x "homem mordeu cão" deu 1,00? Gato x felino deu o mesmo que gato x servidor?

COMO PONTUAR



+2 matriz e cosseno corretos



+2 primeiro prompt já era especificação



+1 histórico completo entregue

VERIFICAÇÃO

- Comparem com o artefato Bag of Words
- Cosseno de um vetor com ele mesmo tem que dar 1

PARTE 2: TOKENIZAÇÃO

O modelo não lê letras nem palavras

O MODELO NÃO LÊ LETRAS

tokenização	`token` `ização`	2 TOKENS
tokenization	`token` `ization`	2 TOKENS
desenvolvedor	`des` `envol` `vedor`	3 TOKENS
developer	`developer`	1 TOKEN
autenticação	`aut` `ent` `icação`	3 TOKENS
authentication	`authentication`	1 TOKEN

TOKEN

Pedaço de texto

Pode ser uma palavra inteira, uma sílaba, um prefixo, um espaço ou pontuação.

O modelo só vê números: o id de cada token no vocabulário.

Vocabulários atuais: 100 mil a 200 mil tokens.

COMO O BPE APRENDE OS PEDAÇOS

01

Bytes

Vocabulário inicial: os 256 bytes

02

Contar pares

O par adjacente mais frequente no corpus

03

Fundir

O par vira um token novo do vocabulário

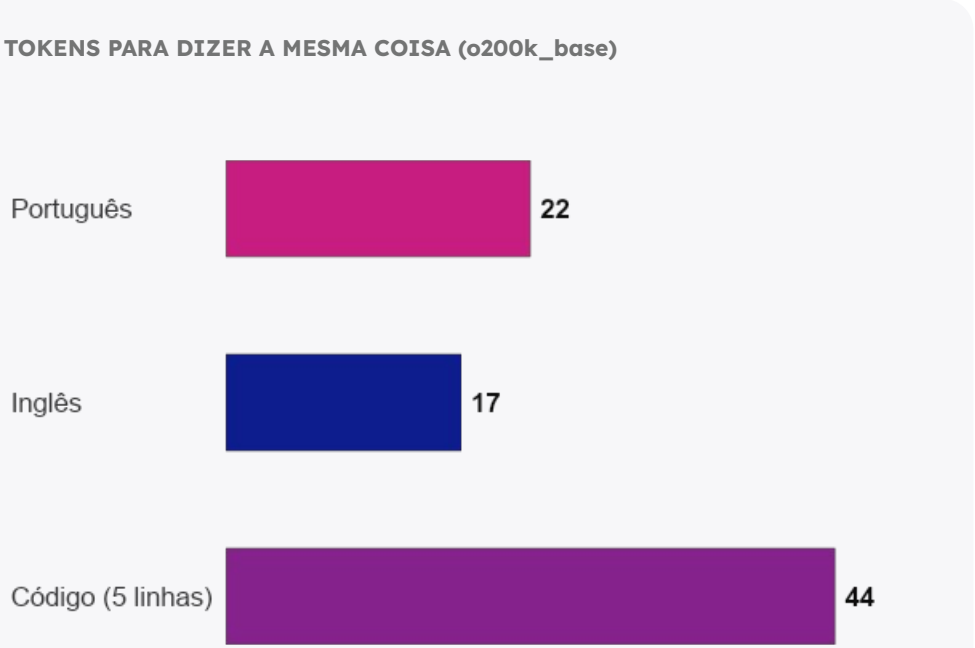
04

Repetir

Até o tamanho escolhido: 100k, 200k

Só frequência, nada de gramática: o que aparece muito no treino vira um token só. O inglês aparece muito mais.

PORTUGUÊS CUSTA MAIS



4,1 caracteres por token em português

5,6 caracteres por token em inglês

4,4 caracteres por token em código

CÓDIGO MÍNIMO: CONTAR TOKENS

tokens.py

```
import tiktoken

enc = tiktoken.get_encoding("o200k_base")

texto = "O desenvolvedor refatorou a função"
ids = enc.encode(texto)

print(len(texto), "caracteres")
print(len(ids), "tokens")
print([enc.decode([t]) for t in ids])

# 34 caracteres
# 8 tokens
# ['O', ' desenvolved', 'or', ' refator', 'ou', ' a', ' fun', 'ção']
```

O QUE OBSERVAR

Três detalhes

- O espaço vai junto: o token é ′ refator′, com espaço
- A mesma palavra pode quebrar diferente conforme a vizinhança
- O vocabulário baixa uma vez e fica em cache
- o200k_base é o do GPT-4o em diante; cl100k_base, dos anteriores

HANDS-ON 2: RECRIE O BPE

1 Explorem e especifiquem

5 MIN

Usem o artefato Tokenizador BPE. Escrevam a spec: corpus entra, lista de merges sai, texto novo é tokenizado.

2 Construam com IA

18 MIN

Treino com N merges, mostrando cada merge. Depois tokenizem uma frase nova usando só a lista de merges.

3 Confiram

7 MIN

Rodem com o corpus do artefato. Os 10 primeiros merges batem? Se não, descubram por quê.

COMO PONTUAR

+2	treino e tokenização funcionando
+2	10 primeiros merges iguais ao artefato
+2	spec e histórico entregues

DICA

- Palavras separadas só por espaço; pontuação fica grudada
- Empate: vence o par menor na ordem Unicode

PARTE 3: O ESPAÇO VETORIAL

Do esparso ao denso, de vetor a significado

DO ESPARSO AO DENSO

1954	1975	2003	2013	2017	HOJE
Harris	**Salton**	**Bengio**	**Word2Vec**	**Transformer**	**LLMs**
Sentido vem do contexto de uso	Documento vira vetor de contagens	Rede neural aprende vetores de palavras	Cerca de 300 números densos por palavra	O vetor muda conforme a frase	Milhares de números por token

De 50 mil colunas quase vazias a vetores densos, em que distância vira sentido

DE TOKEN A VETOR

01

Token

" gato" é o id 9304 do vocabulário

02

Vetor

O id vira um vetor de milhares de números aprendidos

03

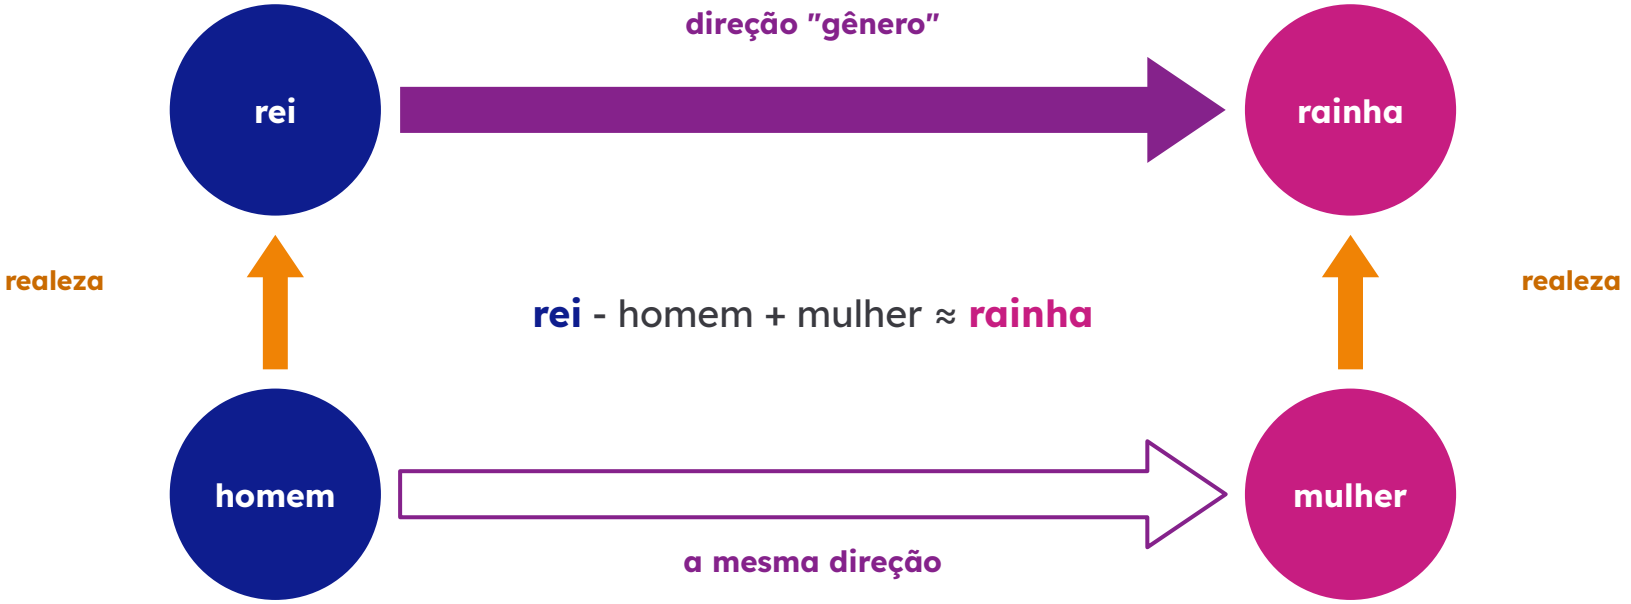
Posição

Perto: cachorro, felino. Longe: compilador

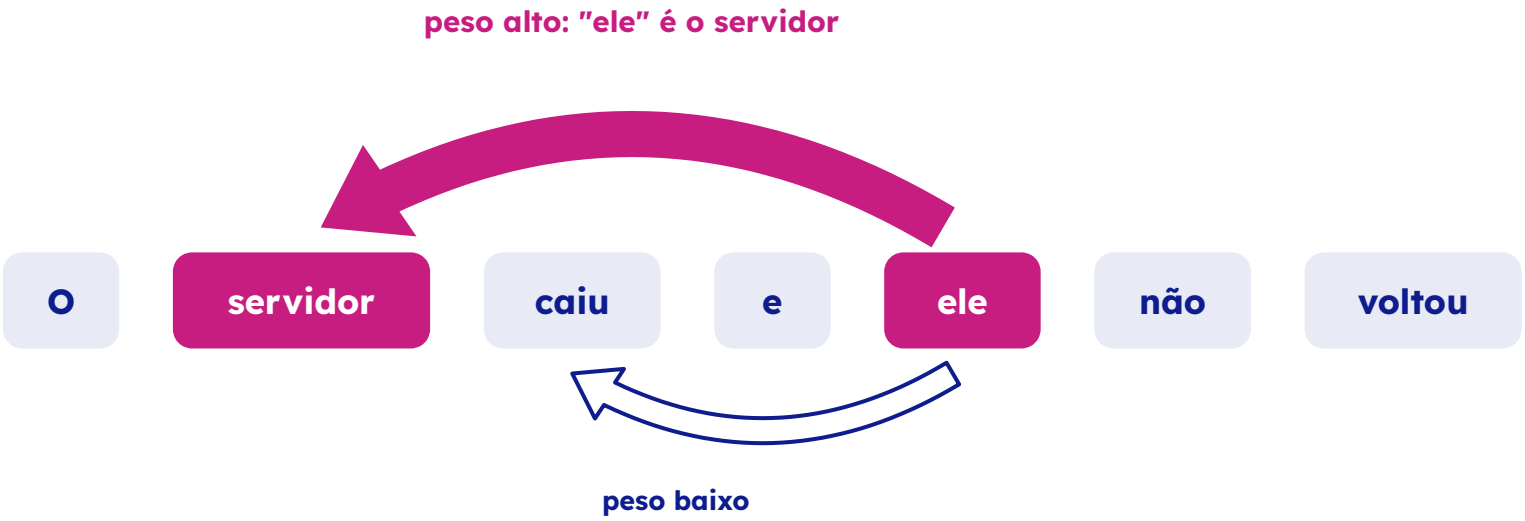
```
" gato"
[ 0.021, -0.173,  0.448,  0.009, -0.312,  0.127,  ... milhares de números ...,  0.084 ]
```

A posição nesse espaço é o "significado" que o modelo conhece. Distância pequena = uso parecido.

ARITMÉTICA COM SIGNIFICADO



ATENÇÃO: QUEM OLHA PARA QUEM



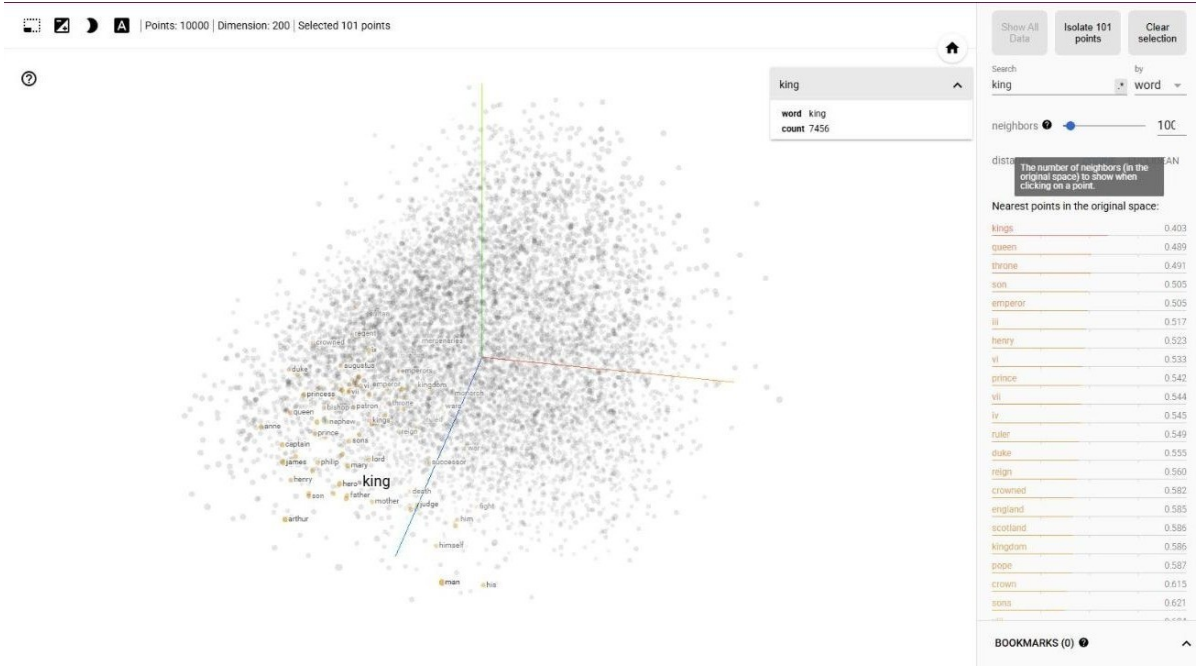
Custo: cada token se compara com todos os anteriores. Dobrar o contexto mais que dobra o trabalho. Guarde isso para a aula 3.

O TRANSFORMER EM UM SLIDE



o token gerado vira contexto do próximo passo

O ESPAÇO EM 3 DIMENSÕES



WORD2VEC 10K

Vizinhos de "king"

- kings 0,40 e queen 0,49: os mais próximos
- throne, emperor, prince, ruler, crown
- Nenhuma definição foi ensinada: só contexto de uso
- PCA leva 200 dimensões para 3: perto no 3D é pista, não prova

HANDS-ON 3: SEU ESPAÇO EM 3D

1 Especifiquem

5 MIN

No Google Colab: 30 palavras em 3 grupos, embeddings de um modelo real, PCA para 3D e gráfico interativo.

2 Construam com IA

10 MIN

Sugestão: sentence-transformers com paraphrase-multilingual-MiniLM-L12-v2 (384 dimensões) e Plotly.

3 Interpretem

5 MIN

Os grupos se separaram? Qual palavra caiu no lugar errado e por quê? Quanto da variância o PCA manteve?

COMO PONTUAR

+2	3D com modelo real, sem coordenada inventada
+2	explicou a palavra fora do lugar
+2	spec e histórico entregues

PLANO B

- Colab travou: Embedding Projector com seus vetores (Load)
- Grupo travado: professor roda no projetor

O QUE VIMOS E O QUE VEM

BAG OF WORDS

Contagem esparsa: sem sentido e sem ordem

TOKENS

O BPE aprende pedaços por frequência; português custa mais

VETORES

Denso: sentido é posição, e o contexto muda o vetor

USO DE IA

Especificar antes, conferir depois

AULA 3 · QUI 22/10

Os limites da máquina

- Temperatura e o sorteio do próximo token
- Janela de contexto: até onde o modelo vê
- Data de corte, alucinação e pacotes que não existem
- Mais contexto não é melhor


<LAB365>
SENAI