SEMANA 3 · AULA 2 · 04/11

COMO SE FAZ UMA SKILL

O passo a passo, o gatilho medido e a troca de skills entre equipes

Felipe Oliveira · IA Aplicada à Produtividade no Desenvolvimento

<LAB365> SENAI

ONDE PARAMOS

?

achados confirmados ontem (melhor equipe)

?

falsos positivos somados

12

requisitos na spec

72%

meta de hoje (Rajan 2025)

A PERGUNTA DE HOJE

Ontem a v0 revisou o vizinho. Hoje: como se faz uma skill boa, de propósito e não por sorte? E como saber se a do vizinho é boa?

PARTE 1: GATILHO

Descrições competem pelo mesmo 1% da janela. Near-miss é o teste que vale.

PARTE 2: O OFÍCIO

Seis passos para criar uma skill que dispara certo, faz o que promete e cabe no contexto.

AGENDA DA AULA

19h00	Placar da revisão cruzada e a pergunta de hoje	ABERTURA
19h10	Bloco 3: o problema do gatilho	TEORIA
19h30	Atividade 2.1: O gatilho certo	PRÁTICA
20h00	Intervalo	PAUSA
20h10	Bloco 4: como se faz uma skill, em seis passos	TEORIA
20h30	Atividade 2.2: criar duas skills finas	PRÁTICA
21h05	Disputa 2: troca e avaliação de skills	DISPUTA
21h25	Placar, o que fica, amanhã	FECHO

ENTREGÁVEL DE HOJE

Duas skills finas

- 2 skills review-* novas, pelo passo a passo
- descrição medida com near-miss
- evals.json com 3 casos cada
- frontmatter válido (validate.py)
- avaliação da skill da vizinha (rubrica)

BLOCO 3: O PROBLEMA DO GATILHO

Uma descrição boa não basta quando há dez descrições

DEZ DESCRIÇÕES, UM GATILHO

LISTAGEM NO CONTEXTO (NÍVEL 1)

review-security	description: ...
review-correctness	description: ...
review-performance	description: ...
pr-summary	description: ...
pytest-runner	description: ...
git-commit-msg	description: ...
lint-fix	description: ...
docs-writer	description: ...



"olha esse PR, acho que tem algo errado no estorno"

o modelo escolhe pela proximidade semântica

1%
da janela para a listagem

1.536
caracteres por descrição

FALHAS TÍPICAS DO GATILHO

GÊMEAS

Duas descrições parecidas

EFEITO

As duas disparam (instruções conflitantes) ou nenhuma. Diferencie pelo que cada uma NÃO faz.

ESTREITA

Só dispara com a palavra exata

EFEITO

"revisa a segurança" dispara; "tem alguma falha nisso?" não. Liste os jeitos de pedir.

LARGA

Dispara em tudo que tem código

EFEITO

"escreve testes" carrega a skill de review. Diga o que ela não cobre.

TAREFA SIMPLES

O agente acha que não precisa

EFEITO

Pedido de um passo não consulta skill. Use /nome ou mencione o fluxo na descrição.

NEAR-MISS: O TESTE QUE VALE

NEGATIVO FRACO

Não testa nada

exemplo	"escreve uma função fibonacci"
exemplo	"qual a previsão do tempo?"
por quê	sem vocabulário em comum; qualquer descrição passa

vs

NEGATIVO FORTE

Compartilha palavras, pede outra coisa

exemplo	"adiciona log de auditoria em refund()" (puxa security)
exemplo	"cria um índice pra customer_id" (puxa performance)
por quê	só uma descrição precisa dispara aqui

Receita: 8 a 10 prompts que devem disparar, 8 a 10 near-misses, 3 rodadas cada; taxa > 0,5 nos positivos e < 0,5 nos negativos.

COMO MEDIR O GATILHO

PASSO 1

20 prompts

8 a 10 positivos variando formalidade e explicitude; 8 a 10 near-misses.

PASSO 2

Treino 60/40

60% para guiar as mudanças, 40% só para conferir se generalizou.

PASSO 3

3 rodadas

Modelo é não determinístico: taxa de disparo, não acerto único.

PASSO 4

Revisar

Falhou positivo: amplie o escopo. Disparou negativo: diga o que não faz.

PASSO 5

Escolher

A melhor iteração pela validação, não a última. Até 5 iterações.

Armadilha: colar as palavras do prompt que falhou na descrição é sobreajuste. Descreva a categoria, não a frase.

ATIVIDADE 2.1: O GATILHO CERTO

Quatro descrições, vinte prompts, cinco rodados de verdade

O GATILHO CERTO: COMO JOGAR

PASSO 1

Escrever (10 min)

Descrições de review-security, review-correctness, review-performance e pr-summary.

PASSO 2

Prever (10 min)

20 prompts projetados. Para cada um, qual skill dispara? Ou nenhuma?

PASSO 3

Rodar (10 min)

5 prompts sorteados rodam na sua ferramenta com as suas descrições.

EVENTO	PONTOS
previsão correta	+1
disparo real correto	+2
disparo em near-miss (11 a 20)	-1

DICA

Diga o que não faz

"Não escreve testes nem faz deploy."

BLOCO 4: COMO SE FAZ UMA SKILL

Seis passos, do tamanho certo ao teste, e uma rubrica para julgar a dos outros

SKILL É FUNÇÃO, NÃO MONÓLITO

ESTREITA DEMAIS

review-sqli

problema 10 skills para uma tarefa

efeito sobrecarga e instruções conflitantes

COERENTE

review-security

cobre injeção, auth, segredos, logs

efeito dispara com precisão e compõe bem

LARGA DEMAIS

review-all

problema 930 linhas, 40 regras

efeito não dispara com precisão; fábrica de FP

> **"Deciding what a skill should cover is like deciding what a function should do."** agentskills.io, Best practices.

SEIS PASSOS PARA UMA SKILL

PASSO 1

Tarefa

Do tamanho de uma função; faça à mão uma vez.

PASSO 2

Gotchas

Cada correção que você deu vira uma linha.

PASSO 3

Descrição

O quê + quando + o que não faz. Teste com near-miss.

PASSO 4

Corpo

Procedimento, template de saída, checklist. < 500 linhas.

PASSO 5

Scripts

Determinístico em scripts/; longo e raro em references/.

PASSO 6

Teste

validate.py, 3 rodadas, 2 ou 3 evals com e sem skill.

Regra de ouro: a skill nasce de uma tarefa real feita com correções, nunca de um pedido vazio ao modelo.

PASSOS 1 E 2: TAREFA E GOTCHAS

PASSO 1

Uma tarefa, feita à mão

tarefa	revisar refunds.py quanto a dinheiro (R01, R04)
tamanho	uma função: dinheiro, não 'tudo'
como	sessão sem skill; você corrige o agente

PASSO 2

Correções viram gotchas

você disse	"dinheiro é int em centavos"
você disse	"parcial soma os reembolsos anteriores"
vira	seção Gotchas + o que procurar

Com a transcrição na mão: "extraia desta sessão os erros que você cometeu e o que eu corrigi". É daí que sai a skill, não de "escreva uma skill de review".

PASSOS 3 E 4: DESCRIÇÃO E CORPO

review-money/SKILL.md

```
---
name: review-money
description: >
  Revisa codigo Python que mexe com dinheiro:
  centavos, arredondamento, reembolso, saldo.
  Use quando pedirem review de pagamento,
  estorno, valor, taxa. Nao revisa seguranca.
---
## Gotchas
- Dinheiro e int em centavos; float e bug (R01)
- Reembolso parcial soma os anteriores (R04)
## Procedimento
1. Leia a spec (R01, R02, R04, R05)
2. Para cada funcao com valor: tipo, soma, limite
3. Preencha a tabela de achados (template abaixo)
## Template de saida
| arquivo | linha | sev | req | evidencia |
```

CHECKLIST DO CORPO

O que não pode faltar

- descrição: o quê, quando, o que não faz
- gotchas do projeto (do passo 2)
- procedimento numerado
- template de saída com requisito
- o que NÃO fazer (escopo)
- menos de 500 linhas

PASSOS 5 E 6: SCRIPTS E TESTE

PASSO 5

Scripts e references

scripts/	collect_diff.sh, validate_report.py: determinístico, zero tokens
references/	cwe-top25.md, lido só se a tarefa pedir
sinal	o agente escreveu o mesmo helper duas vezes

PASSO 6

Validar e medir

frontmatter	python validate.py <pasta>
gatilho	3 rodadas, positivos e near-misses
evals	2 a 3 casos com e sem skill; um near-miss

Poda: instrução que não muda o resultado sai; assertion que passa sempre sai. Skill enxuta vence skill completa.

USAR O AGENTE PARA ESCREVER A SKILL

NÃO FUNCIONA

Pedido vazio

prompt	"escreva uma skill de code review"
sai	"handle errors appropriately"
por quê	sem gotchas, sem projeto, sem formato

vs

FUNCIONA

Pedido alimentado

prompt	"a partir desta transcrição, da spec e deste template, escreva a skill"
sai	gotchas reais, procedimento do projeto
depois	medir o gatilho e podar

skill-creator (anthropics/skills): automatiza evals, A/B cego e afinação da descrição. Mesmo princípio: entra transcrição e feedback, sai skill.

RUBRICA: A SKILL DO VIZINHO É BOA?

CRITÉRIO	0	1	2
Descrição	vaga ou só o nome	diz o quê, mas não quando	o quê + quando + o que não faz
Gotchas	nenhum	genéricos	do projeto, verificáveis na spec
Procedimento e template	prosa solta	passos sem formato de saída	passos + template com requisito
Tamanho e disclosure	monólito ou enciclopédia	cabe, mas repete o óbvio	enxuta; longo foi para references/
Determinismo	tudo no modelo	cita scripts sem usar	scripts/ para o repetível
Segurança	rede ou segredo	pede permissão larga	nada de rede, nada escondido

Mais o gatilho: 5 prompts (3 devem disparar, 2 near-misses), +1 por acerto. Máximo 17 por skill. Nota sem a linha do SKILL.md que a justifica não vale.

ATIVIDADE 2.2: CRIAR DUAS SKILLS

35 minutos: duas skills finas de review, pelos seis passos

CRIAR DUAS SKILLS: COMO JOGAR

PASSO 1

Escolher 2

Da família review-* (security, correctness, performance, money) ou pr-summary.

PASSO 2

À mão (5 min)

Revise o projeto vizinho com o agente, sem skill. Anote cada correção.

PASSO 3

Escrever

Passos 2 a 5: gotchas, descrição, corpo, scripts/references.

PASSO 4

Testar

validate.py; 3 rodadas de gatilho; evals.json com 3 casos.

PASSO 5

Entregar

Pasta de skills do repo da equipe, por PR, até 21h05.

Divisão: uma pessoa faz à mão e anota, outra escreve a descrição e os prompts de teste, outra o corpo e os scripts. Depois troquem de lugar para a segunda skill.

DISPUTA 2: TROCA E AVALIAÇÃO

PASSO 1

Rodízio

1 avalia 2, 2 avalia 3, última avalia 1. Clone e instale as duas skills.

PASSO 2

Rubrica

6 critérios, 0 a 2, com a linha do SKILL.md que justifica cada nota.

PASSO 3

Gatilho

Escreva 3 prompts que devem disparar e 2 near-misses. Rode. +1 por acerto.

PASSO 4

Devolver

Ficha por PR no repo da equipe avaliada. Pontos da criadora: soma das duas skills.

Placar: até 17 pontos por skill (34 por equipe), +3 para a avaliação mais bem justificada. Acumula com as rodadas 1 e 3.

O QUE FICA E O QUE VEM

FICA

Skill nasce de uma tarefa feita à mão: gotchas, descrição medida, corpo com template, scripts, teste.

TRAGA AS SKILLS FUNCIONANDO

Quinta elas são a arma do Blue Team no Torneio e a base do seu trabalho final.

QUINTA (05/11)

Spec, steering e skills do SEU trabalho final; skills seguras; o Torneio Red x Blue.

LISTA DA SEMANA

Suíte no GitHub, evals.json + benchmark, auditoria de uma skill pública, 5 linhas do projeto. Entrega 09/11.

6

passos para uma skill

17

pontos máximos na rubrica

50

min de Torneio na quinta

5

bugs que você vai plantar


<LAB365>
SENAI