SEMANA 3 · AULA 2 · 04/11

COMO SE FAZ UMA SKILL

Seis passos na primeira metade, um duelo de skills na segunda

Felipe Oliveira · IA Aplicada à Produtividade no Desenvolvimento

<LAB365> SENAI

AGENDA DA AULA

19h00	Bloco 3: como se faz uma skill, em seis passos	TEORIA
19h25	Demo ao vivo: o gatilho medido (passo 3)	DEMO
19h45	Demo ao vivo: o agente escreve a skill (passo 6)	DEMO
19h55	Sorteio: 3 temas, 2 equipes por tema	DUELO
20h00	Intervalo	PAUSA
20h20	Duelo, fase 1: criar a skill	DISPUTA
20h55	Duelo, fase 2: testar a skill da adversária	DISPUTA
21h20	Julgamento, placar da semana, amanhã	FECHO

O DUELO DE HOJE

Uma skill por equipe

- 6 equipes, 3 temas de review, 2 equipes por tema
- quem roda a sua skill é a adversária
- bancada: pagamentos-api (main e clean)
- vence quem acha mais bugs do tema com menos erro
- campeã da noite: maior placar entre as 3 vencedoras

BLOCO 3: COMO SE FAZ UMA SKILL

Seis passos, do tamanho certo ao teste, com o gatilho medido no meio

SKILL É FUNÇÃO, NÃO MONÓLITO

ESTREITA DEMAIS

review-sqli

problema 10 skills para uma tarefa

efeito sobrecarga e instruções conflitantes

COERENTE

review-security

cobre injeção, auth, segredos, logs

efeito dispara com precisão e compõe bem

LARGA DEMAIS

review-all

problema 930 linhas, 40 regras

efeito não dispara com precisão; fábrica de FP

> **"Deciding what a skill should cover is like deciding what a function should do."** agentskills.io, Best practices.

SEIS PASSOS PARA UMA SKILL

PASSO 1

Tarefa

Do tamanho de uma função; faça à mão uma vez.

PASSO 2

Gotchas

Cada correção que você deu vira uma linha.

PASSO 3

Descrição

O quê + quando + o que não faz. Teste com near-miss.

PASSO 4

Corpo

Procedimento, template de saída, checklist. < 500 linhas.

PASSO 5

Scripts

Determinístico em scripts/; longo e raro em references/.

PASSO 6

Teste

validate.py, 3 rodadas, 2 ou 3 evals com e sem skill.

Regra de ouro: a skill nasce de uma tarefa real feita com correções, nunca de um pedido vazio ao modelo.

PASSOS 1 E 2: TAREFA E GOTCHAS

PASSO 1

Uma tarefa, feita à mão

tarefa	revisar refunds.py quanto a dinheiro (R01, R04)
tamanho	uma função: dinheiro, não 'tudo'
como	sessão sem skill; você corrige o agente

PASSO 2

Correções viram gotchas

você disse	"dinheiro é int em centavos"
você disse	"parcial soma os reembolsos anteriores"
vira	seção Gotchas + o que procurar

Com a transcrição na mão: "extraia desta sessão os erros que você cometeu e o que eu corrigi". É daí que sai a skill, não de "escreva uma skill de review".

PASSO 3: DESCRIÇÃO E GATILHO

NEGATIVO FRACO

Não testa nada

exemplo	"escreve uma função fibonacci"
exemplo	"qual a previsão do tempo?"
por quê	sem vocabulário em comum; qualquer descrição passa

vs

NEAR-MISS

Compartilha palavras, pede outra coisa

exemplo	"adiciona log de auditoria em refund()" (puxa security)
exemplo	"escreve o teste do reembolso" (puxa money)
por quê	só uma descrição precisa não dispara aqui

Demo ao vivo: 4 skills instaladas, 6 prompts de trigger-eval.json, 3 rodadas cada. Vocês preveem antes, o agente responde depois. Receita: positivos > 0,5, near-misses < 0,5.

PASSO 4: O CORPO DA SKILL

review-money/SKILL.md

```
---
name: review-money
description: >
  Revisa codigo Python que mexe com dinheiro:
  centavos, arredondamento, reembolso, saldo.
  Use quando pedirem review de pagamento,
  estorno, valor, taxa. Nao revisa seguranca.
---
## Gotchas
- Dinheiro e int em centavos; float e bug (R01)
- Reembolso parcial soma os anteriores (R04)
## Procedimento
1. Leia a spec (R01, R02, R04, R05)
2. Para cada funcao com valor: tipo, soma, limite
3. Preencha a tabela de achados (template abaixo)
## Template de saida
| arquivo | linha | sev | req | evidencia |
```

CHECKLIST DO CORPO

O que não pode faltar

- descrição: o quê, quando, o que não faz
- gotchas do projeto (do passo 2)
- procedimento numerado
- template de saída com requisito
- o que NÃO fazer (escopo)
- menos de 500 linhas

PASSOS 5 E 6: SCRIPTS E TESTE

PASSO 5

Scripts e references

scripts/	collect_diff.sh, validate_report.py: determinístico, zero tokens
references/	cwe-top25.md, lido só se a tarefa pedir
sinal	o agente escreveu o mesmo helper duas vezes

PASSO 6

Validar e medir

frontmatter	python validate.py <pasta>
gatilho	3 rodadas, positivos e near-misses
evals	2 a 3 casos com e sem skill; um near-miss

Poda: instrução que não muda o resultado sai; assertion que passa sempre sai. Skill enxuta vence skill completa.

USAR O AGENTE PARA ESCREVER A SKILL

NÃO FUNCIONA

Pedido vazio

prompt	"escreva uma skill de code review"
sai	"handle errors appropriately"
por quê	sem gotchas, sem projeto, sem formato

vs

FUNCIONA

Pedido alimentado

prompt	"a partir desta transcrição, da spec e deste template, escreva a skill"
sai	gotchas reais, procedimento do projeto
depois	medir o gatilho e podar

skill-creator (anthropics/skills): automatiza evals, A/B cego e afinação da descrição. Mesmo princípio: entra transcrição e feedback, sai skill.

DISPUTA 2: O DUELO DAS SKILLS

Seis equipes, três temas, uma skill por equipe, testada pela adversária

O DUELO: COMO FUNCIONA

PASSO 1

Sorteio

3 temas, 2 equipes por tema: security, correctness, money.

PASSO 2

Criar (35 min)

Uma skill, pelos seis passos, no projeto da sua equipe.

PASSO 3

Trocar

A adversária instala a sua skill. SKILL.md intocado, sessão nova.

PASSO 4

Testar (25 min)

pagamentos-api: main (bugs), clean (zero) e 5 prompts de gatilho.

PASSO 5

Julgar

score.py contra o gabarito. Vence o duelo; campeã entre as 3.

Por que a adversária roda: se a skill só funciona com a criadora explicando do lado, a descrição e o procedimento falharam. É isso que o duelo mede.

FASE 1: CRIAR A SKILL (35 MIN)

PASSO 1

À mão (5 min)

Peça o review do tema no SEU projeto, sem skill. Anote cada correção.

PASSO 2

Gotchas

Cada correção vira uma linha, com o requisito da spec (R__).

PASSO 3

Escrever

template/review-tema: o quê, quando, o que não faz; procedimento; saída com linha.

PASSO 4

Scripts

grep do repetível em scripts/. Longo e raro em references/.

PASSO 5

Congelar

validate.py, 3 rodadas de gatilho, PR no repo da equipe até 20h55.

Divisão: uma pessoa faz à mão e anota, outra escreve descrição e prompts de gatilho, outra procedimento e scripts. Quem terminar primeiro escreve os near-misses.

FASE 2: TESTAR A ADVERSÁRIA (25 MIN)



PASSO 1

Instalar

Clone o repo da adversária. Copie a skill. Não edite nada.



PASSO 2

Na main

Sessão nova, pedido no vocabulário do tema. Saída com linha.



PASSO 3

Na clean

Mesmo pedido. Zero bugs lá: cada achado é erro.



PASSO 4

Gatilho

5 prompts seus: 3 devem disparar, 2 near-misses. Anote o que carregou.



PASSO 5

Entregar

3 arquivos em reports/ por PR no repo da criadora, até 21h20.



Regra: quem testa não corrige a skill nem repete o pedido até sair bonito. Uma rodada por branch, a primeira resposta vale.

PLACAR DO DUELO

EVENTO	PONTOS
bug do tema encontrado (3 por tema)	+3
bug de outro tema (até 2)	+1
falso positivo na main	-2
qualquer achado na clean	-2
prompt de gatilho certo (5)	+1

Quem pontua: o professor, com score_duelo.py e o gabarito lacrado, a partir dos 3 arquivos que a adversária entregou.

COMO VENCER

Acerto alto, erro baixo

- máximo 16 pontos por skill
- vence o duelo quem pontua mais no tema
- campeã da noite: maior placar entre as 3 vencedoras
- desempate: menos falsos positivos, depois gatilho
- achado sem linha não casa com nada: zero
- entra no placar da semana com a Disputa 1 e o Torneio

O QUE FICA E O QUE VEM

FICA

Skill nasce de uma tarefa feita à mão: gotchas, descrição medida, corpo com template, scripts, teste.

TRAGA A SKILL FUNCIONANDO

Quinta ela é a arma do Blue Team no Torneio e a base do seu trabalho final.

QUINTA (05/11)

Spec, steering e skills do SEU trabalho final; skills seguras; o Torneio Red x Blue.

LISTA DA SEMANA

Suíte completa no GitHub, evals.json + benchmark, auditoria de uma skill pública, 5 linhas do projeto. Entrega 09/11.

6

passos para uma skill

16

pontos máximos no duelo

50

min de Torneio na quinta

5

bugs que você vai plantar


<LAB365>
SENAI